

Optimización de Red Neuronal Informada por la Física al Caso de Klein-Gordon Homogéneo

Sierra Salamanca Julián

19 de agosto de 2026

Resumen

En este trabajo se presenta el problema del optimizar la función de costo de la red neuronal informada por la física (PINN) como aproximador a la función solución de la ecuación de Klein-Gordon homogénea en dos dimensiones, dimensión espacial y el tiempo. Se usa el método de variables separables y propagadores como solución control del método. Se expone la formulación matemática de los métodos numéricos usados, de la PINN y del problema a optimizar a partir de las condiciones KKT. Con esto, se propone los algoritmos ADAM + LRA y L-BFGS como optimizadores de esta función y se analizará su convergencia de manera experimental.

1. Introducción

Los físicos Oscar Klein y Walter Gordon en 1926 propusieron la ecuación de Klein-Gordon como la ecuación que modela la dinámica de los electrones relativistas; mas sin embargo, años posteriores la ecuación de Klein-Gordon (ecuación de onda disufiva) describe, también, perturbaciones (ondas) como densidades del campo bosónico (partículas de spin-0). En otras palabras, los físicos Oscar Klein y Walter Gordon descubrieron una ecuación que describe el comportamiento de partículas bosónicas (cuánticas) relativistas (Castro G. V., 2018).

La naturalidad de esta ecuación (ecuación diferencial parcial hiperbólica), permite hayar la solución a partir de métodos exactos, siempre y cuando la solución sea homogénea y lineal, o en su defecto, aplicar métodos numéricos para otros tipos de soluciones, como es el caso de la ecuación de Klein Gordon no lineal, le agregan . (Castro G. V., 2018).

Gracias al desarrollo de una amplia gama de disciplinas, las redes neuronales como métodos numéricos rápidos y sencillo de entrenar para tareas bastantas específicas han sido estudiadas en diversas aplicaciones. Las redes neuronales informadas por la física (PINNs) son especialmente redes neuronales que acogen leyes físicas a través de EDPs y las involucran en su proceso de ajuste de parámetros para no ser violados. En este proyecto, se desarrollará la PINN como método numérico alternativo para la solución de la ecuación de Klein-Gordon lineal y no lineal, y se estudiará y se identificará los problemas de convergencia de la minimización de la función de costo, como problemas de valles generados por la no convexidad del espacio de solución.

2. Planteamiento del problema

¿Cómo es la evolución temporal de una partícula estática con masa m y espin 0 bajo la observación de la relatividad cuántica confinada en una caja del tamaño del electrón y luego liberada al espacio infinito? La idea de estas simulaciones es observar la energía en reposo ($E = mc^2$) y la dispersión cuántica de esta energía. A su vez, observar las características de la solución y un desafío "simple" pero interesante para el entrenamiento y optimización de una PINN.

3. Ecuación de Klein-Gordon

Se considera la ecuación de Klein-Gordon para el estudio de la dispersión del electrón libre (Anexo 1). Matematicamente, estamos hablando de una ecuación diferencial parcial hiperbólica para un campo escalar:

$$\underbrace{\frac{1}{c^2} \frac{\partial^2}{\partial t^2} \phi(\mathbf{x}, t)}_{\text{Evolución temporal}} - \underbrace{\nabla^2 \phi(\mathbf{x}, t)}_{\text{Difusión}} + \underbrace{\left(\frac{mc}{\hbar} \right)^2 \phi(\mathbf{x}, t)}_{\text{Fuerza restauradora}} = 0. \quad (1)$$

Dónde encontramos el término de segunda derivada temporal ∂_{tt} como una fuerza que induce el cambio y la dinámica del sistema, el término de difusión ∇^2 y un término de m^2 que actúa como una fuerza restauradora. La ecuación de Klein-Gordon se puede interpretar en una sola dimensión espacial como una onda que perturba una cuerda en un tiempo arbitrario.

Se quiere que la solución contenga las frecuencias $e^{\pm i\mathbf{k}\cdot\mathbf{x}}$. Esta solución se puede hallar mediante el método de separación de variables propuesto por Fourier:

$$\phi(\mathbf{x}, t) = \Psi(\mathbf{x})T(t). \quad (2)$$

Hallamos las derivadas temporales y espaciales:

$$\frac{\partial^2 \phi}{\partial t^2} = \Psi(\mathbf{x})T''(t) \quad (3)$$

$$\frac{\partial^2 \phi}{\partial x^2} = \Psi''(\mathbf{x})T(t). \quad (4)$$

Reemplazando esta solución a la ecuación diferencial:

$$\frac{1}{c^2} \Psi(\mathbf{x})T''(t) - \Psi''(\mathbf{x})T(t) + \left(\frac{mc}{\hbar}\right)^2 \Psi(\mathbf{x})T(t) = 0. \quad (5)$$

Separamos variables:

$$\frac{1}{c^2} \frac{T''(t)}{T(t)} + \mu^2 = \frac{\Psi''(\mathbf{x})}{\Psi(\mathbf{x})}$$

Dónde $\mu = mc/\hbar$. Para que esta identidad se cumpla cada término, el derecho y el izquierdo de la igualdad deben ser igual a una constante $-k^2$, de este modo, obtenemos ODEs para cada función por separado:

$$\frac{1}{c^2} T''(t) + i\omega_k^2 T(t) = 0, \quad \Psi''(\mathbf{x}) + k^2 \Psi(\mathbf{x}) = 0.$$

En dónde, $\omega_k^2 = (\mu^2 + k^2)$; ambas son ecuaciones diferenciales del armónico simple, por lo tanto sus soluciones son:

$$\Psi(\mathbf{x}) = Ae^{i\mathbf{k}\cdot\mathbf{x}} + Be^{-i\mathbf{k}\cdot\mathbf{x}}, \quad (6)$$

$$T(\mathbf{x}) = Ce^{i\omega_k t} + De^{-i\omega_k t}. \quad (7)$$

Actualizando las soluciones de cada función se obtiene la solución general del campo de Klein-Gordon,

$$\begin{aligned} \phi(\mathbf{x}, t) &= \Psi(\mathbf{x})T(t) \\ &= (Ae^{i\mathbf{k}\cdot\mathbf{x}} + Be^{-i\mathbf{k}\cdot\mathbf{x}})(Ce^{i\omega_k t} + De^{-i\omega_k t}) \\ &= K_1 e^{i(\mathbf{k}\cdot\mathbf{x} - \omega_k t)} + K_2 e^{-i(\mathbf{k}\cdot\mathbf{x} - \omega_k t)}. \end{aligned} \quad (8)$$

Siendo $\mathbf{x} = (x, y, z)$ y $\mathbf{k} = (k_x, k_y, k_z)$. Este resultado se puede generalizar aún más para un electrón con una energía cuantizada en diferentes fases:

$$\phi(\mathbf{x}, t) = \sum_{\mathbf{k}} K_{1\mathbf{k}} e^{i(\mathbf{k}\cdot\mathbf{x} - \omega_k t)} + K_{2\mathbf{k}} e^{-i(\mathbf{k}\cdot\mathbf{x} - \omega_k t)}. \quad (9)$$

Para el caso simple, tenemos que la solución en una dimensión (1-D) es simplemente la solución:

$$\phi(x, t) = \sum_k K_{1k} e^{i(kx - \omega_k t)} + K_{2k} e^{-i(kx - \omega_k t)}. \quad (10)$$

3.1. Condiciones iniciales y de frontera

Las condiciones iniciales y de frontera serán de tal modo que representen una partícula estacionaria, es decir, con posición inicial y velocidad nula.

- **Condición inicial.** Las condiciones iniciales, tanto del campo y de la velocidad del campo, será modelada por un pulso Gaussiano y una función que induzca velocidad en $+k$ y $-k$:

$$\phi(\mathbf{x}, 0) = \underbrace{Ae^{-(\mathbf{x}^2/2\sigma)}}_{\text{Gaussiana}} \underbrace{\sum_{\mathbf{k}_0} (e^{i\mathbf{k}_0\cdot\mathbf{x}} + e^{-i\mathbf{k}_0\cdot\mathbf{x}})}_{\text{Fase simétrica}}, \quad (\text{Posición}) \quad (11)$$

$$\dot{\phi}(\mathbf{x}, 0) = 0. \quad (\text{Velocidad}) \quad (12)$$

- **Condición de frontera.** En el método pseudoespectral la condición de frontera es una condición periódica.

$$\phi(-L/2, t) = \phi(L/2, t) \quad (13)$$

Sin embargo, en la simulación, la onda no se dispersará hasta la frontera debido a los parámetros establecidos de tiempo y espacio.

Aplicando las condiciones iniciales para el caso en una dimensión (1-D), encontramos que $k_0 = k$:

$$\sum_k K_{1k} e^{ikx} + K_{2k} e^{-ikx} = A e^{-(x^2/2\sigma)} \sum_k (e^{ikx} + e^{-ikx}) \quad (14)$$

$$\sum_k (K_{1k} - A e^{-(x^2/2\sigma)}) e^{ikx} + (K_{2k} - A e^{-(x^2/2\sigma)}) e^{-ikx} = 0 \quad (15)$$

Cada término en la sumatoria debe anularse; para el caso trivial $(K_{1k} - A e^{-(x^2/2\sigma)}) = (K_{2k} - A e^{-(x^2/2\sigma)}) = 0$ debe cumplirse, así que $K_{1k} = K_{2k} = A e^{-(x^2/2\sigma)} = K_k$. Así que la solución con condición inicial es:

$$\phi(x, t) = \sum_k K_k (e^{i(\mathbf{k} \cdot \mathbf{x} - \omega_k t)} + e^{-i(\mathbf{k} \cdot \mathbf{x} - \omega_k t)}) \quad (16)$$

$$= \sum_k 2K_k \cos(kx - \omega_k t) \quad (17)$$

$$= \underbrace{\left(\sum_k 2K_k \cos(kx) \right)}_{\phi(x,0)} \cos(\omega_k t) + \underbrace{\left(\sum_k 2K_k \sin(kx) \right)}_{\frac{\phi(x,0)}{\omega_k}} \sin(\omega_k t) \quad (18)$$

4. Métodos numérico - Método Pseudoespectral

4.1. Parámetros

La solución de esta ecuación es el comportamiento del campo asociado al electrón libre en estado estacionario bajo efectos relativistas, es decir, que la solución aproximará la idea de un campo infinito y una partícula con diferentes espectros de onda dispersándose en todo el campo.

Para lograr esto es debido que el espacio sea lo suficientemente grande como para modelar un espacio infinito $L \gg \sigma$ y un tiempo corto de simulación. Con esto, Los parámetros iniciales son:

1. **Espacio:** $L \gg \sigma$. ¿Cuántas veces sigma?, las suficientes para no ser alcanzadas, se propone $L \geq |40\sigma|$.
2. **Tiempo de simulación:** Debe cumplir que no choque la frontera. Entonces,

$$T_{\max} < \frac{L/2}{c} = \frac{L}{2} \quad (19)$$

El grosor de la onda es aproximadamente de 4σ , así que queremos que llegue casi a este espacio de diferencia.

$$T_{\max} \approx \frac{L}{2} - 4\sigma \quad (20)$$

3. **Número de shots:** bajo las condiciones CFL (Courant-Friedrichs-Lewy), se elige, arbitrariamente 1000 para generar un buen comportamiento:

- $dt = T_{\max}/N$.
- $dx = L/N$.

De tal modo que. $dx/dt < 1$ para generar una función suave en la simulación, para esto, los pasos de tiempo deben ser mayores que los pasos de espacio.

$$\frac{dx}{dt} = \frac{T_{\max}/N}{L/N} = \frac{T_{\max}}{L} < \frac{40\sigma/2}{40\sigma} = \frac{1}{2} \quad (21)$$

Esto quiere decir, que bajo las condiciones CFL será suave.

4. **Masa:** debido a ecuación de energía relativista de Newton $E = mc^2$, la masa se puede expresar en términos de $m = E/c^2$, así la energía del electrón en cercana a la velocidad de la luz es aproximadamente $m \approx \frac{0.511 \text{ MeV}}{c^2} = 0.511 \text{ MeV}$.

$$m \leq 0.511 \text{ MeV} \quad (22)$$

Para la simulación elegimos la igualdad.

4.2. Método numérico

La solución es exacta, esto permite que, bajo un propagador (Hochbruck & Ostermann, 2010) que la solución converge sin errores numéricos más allá del error de truncamiento, es decir, que lo único que tendremos que hacer es calcular el propagador y realizar iteraciones del espacio y/o tiempo discretizados para actualizar las condiciones necesarias. Bajo la transformación $v = \partial_t \phi$ y $L = m^2 - \nabla^2$, la ecuación de Klein-Gordon se transforma en lo siguiente:

$$\frac{dv}{dt} + L\phi = 0. \quad (23)$$

Podemos plantear una ecuación que:

$$\frac{d}{dt} \begin{pmatrix} \phi \\ v \end{pmatrix} = \underbrace{\begin{pmatrix} 0 & 1 \\ -L & 0 \end{pmatrix}}_{\text{Matriz } A} \begin{pmatrix} \phi \\ v \end{pmatrix}. \quad (24)$$

Si hacemos $y = (\phi(x, t) \quad \dot{\phi}(x, t))^T$, entonces tenemos una EDO de primer orden y su solución:

$$\frac{dy}{dt} + Ay = 0 \implies y(t) = y(0)e^{At}. \quad (25)$$

Así obtenemos el propagador e^{At} , que es responsable de la evolución temporal del campo. Para su tratamiento, expandemos en la serie de Taylor, y encontraremos vectores propios con valores propios del espacio de fases:

$$e^{At} = \sum_{k=0}^{\infty} \frac{(At)^k}{k!} = At + \frac{1}{2!}(At)^2 + \frac{1}{3!}(At)^3 + \dots, \quad (26)$$

y así, vemos que es posible descomponer esta sumatoria en términos de cosenos y senos, de este modo,

$$A^2 = \begin{pmatrix} 0 & 1 \\ -L & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ -L & 0 \end{pmatrix} = \begin{pmatrix} -L & 0 \\ 0 & -L \end{pmatrix} \quad (27)$$

$$A^3 = A^2 A = \begin{pmatrix} 0 & 1 \\ -L & 0 \end{pmatrix} \begin{pmatrix} -L & 0 \\ 0 & -L \end{pmatrix} = \begin{pmatrix} 0 & -L \\ L^2 & 0 \end{pmatrix} \quad (28)$$

$$A^4 = A^2 A^2 = \begin{pmatrix} -L & 0 \\ 0 & -L \end{pmatrix} \begin{pmatrix} -L & 0 \\ 0 & -L \end{pmatrix} = \begin{pmatrix} L^2 & 0 \\ 0 & L^2 \end{pmatrix} \quad (29)$$

$$A^5 = \begin{pmatrix} 0 & L^2 \\ -L^3 & 0 \end{pmatrix} \quad (30)$$

Por iteración, encontramos:

- Para números pares $k = 2n$:

$$A^{2n} = \begin{pmatrix} (-1)^n L^n & 0 \\ 0 & (-1)^n L^n \end{pmatrix} \quad (31)$$

- Para números impares $k = 2n + 1$:

$$A^{2n+1} = \begin{pmatrix} 0 & (-1)^n L^n \\ -(-1)^n L^{n+1} & 0 \end{pmatrix} \quad (32)$$

Y así, podemos encontrar una expresión general para la expansión de Taylor del propagador,

$$e^{At} = \sum_{k=0}^{\infty} \frac{t^{2n}}{(2n)^k} A^{2n} + \sum_{k=0}^{\infty} \frac{t^{2n+1}}{(2n+1)^k} A^{2n+1} \quad (33)$$

$$= \sum_{k=0}^{\infty} \frac{t^{2n}}{(2n)^k} \begin{pmatrix} (-1)^n L^n & 0 \\ 0 & (-1)^n L^n \end{pmatrix} + \sum_{k=0}^{\infty} \frac{t^{2n+1}}{(2n+1)^k} \begin{pmatrix} 0 & (-1)^n L^n \\ -(-1)^n L^{n+1} & 0 \end{pmatrix} \quad (34)$$

$$= \begin{pmatrix} \sum_{k=0}^{\infty} \frac{(-1)^k t^{2k}}{(2k)!} L^k & \sum_{k=0}^{\infty} \frac{(-1)^k t^{2k+1}}{(2k+1)!} L^k \\ -\sum_{k=0}^{\infty} \frac{(-1)^k t^{2k+1}}{(2k+1)!} L^k & \sum_{k=0}^{\infty} \frac{(-1)^k t^{2k}}{(2k)!} L^{k+1} \end{pmatrix} \quad (35)$$

Encontramos que:

$$\cos(t\sqrt{L}) = \sum_{k=0}^{\infty} \frac{(-1)^k t^{2k+1}}{(2k+1)!} L^k, \quad (36)$$

$$\sin(t\sqrt{L}) = \sum_{k=0}^{\infty} \frac{(-1)^k t^{2k}}{(2k)!} L^k L^{1/2} \quad \therefore \quad \frac{\sin(t\sqrt{L})}{\sqrt{L}} = \sum_{k=0}^{\infty} \frac{(-1)^k t^{2k}}{(2k)!} L^k. \quad (37)$$

y así,

$$e^{At} = \begin{pmatrix} \cos(t\sqrt{L}) & \frac{\sin(t\sqrt{L})}{\sqrt{L}} \\ -(\sqrt{L})\sin(t\sqrt{L}) & \cos(t\sqrt{L}) \end{pmatrix} \quad (38)$$

Y así obtener la iteración temporal a partir de condiciones iniciales,

$$\begin{pmatrix} \phi(x, t) \\ v(x, t) \end{pmatrix} = \underbrace{\begin{pmatrix} \cos(t\sqrt{L}) & \frac{\sin(t\sqrt{L})}{\sqrt{L}} \\ -(\sqrt{L})\sin(t\sqrt{L}) & \cos(t\sqrt{L}) \end{pmatrix}}_{\text{el propagador } e^{At}} \begin{pmatrix} \phi(x, 0) \\ v(x, 0) \end{pmatrix}. \quad (39)$$

Para evaluar numéricamente el operador L podemos aprovechar que la solución general está en el espacio complejos y por lo tanto, tiene condiciones de frontera periódicas, así que se puede transformar el operador L a partir de la transformada de Fouier

$$\mathcal{F}\left(\frac{dy}{dt} + Ay\right) = \mathcal{F}\left(\frac{dy}{dt}\right) + \mathcal{F}(A)\mathcal{F}(y) \quad (40)$$

$$= \frac{dy_k}{dt} + \begin{pmatrix} 0 & 1 \\ -(k^2 + m^2) & 0 \end{pmatrix} y_k. \quad (41)$$

La transformada de Fourier del operador $\mathcal{F}(L) = m^2 - \mathcal{F}(\nabla^2) = m^2 - (-ik)(-ik) = m^2 + k^2 = \omega_k^2$, y así, obtener un propagador en el espacio de fases:

$$\begin{pmatrix} \phi_k(t) \\ \dot{\phi}_k(t) \end{pmatrix} = \underbrace{\begin{pmatrix} \cos(\omega_k t) & \frac{\sin(\omega_k t)}{\omega_k} \\ -(\omega_k)\sin(\omega_k t) & \cos(\omega_k t) \end{pmatrix}}_{\text{el propagador } e^{\mathcal{F}(A)t}} \begin{pmatrix} \phi_k(0) \\ \dot{\phi}_k(0) \end{pmatrix}. \quad (42)$$

El algoritmo y pseudocódigo:

Algorithm 1 Método Espectral para la Ecuación de Klein-Gordon

Require: Parámetros físicos m, L, T_{max}, N .

Require: Condiciones iniciales $\phi(x, 0)$ y $\dot{\phi}(x, 0)$.

▷ (Ec. 11, 12)

Paso 1: Pre-cómputo del Espacio de Frecuencias

1: $dx \leftarrow L/N, \quad dt \leftarrow T_{max}/N_t$

2: $k \leftarrow \text{fftfreq}(N, dx) \cdot \frac{2\pi}{L}$

3: $\omega_k \leftarrow \sqrt{m^2 + k^2}$

Paso 2: Transformada Inicial

4: $\phi_k(0) \leftarrow \text{FFT}(\phi(x, 0))$

5: $\dot{\phi}_k(0) \leftarrow \text{FFT}(\dot{\phi}(x, 0))$

Paso 3: Bucle de Evolución Temporal

6: $t \leftarrow 0$

7: **while** $t < T_{max}$ **do**

8: *Cálculo de términos del propagador para el paso dt:*

9: $C_k \leftarrow \cos(\omega_k dt)$

10: $S_k \leftarrow \sin(\omega_k dt)$

11: *Aplicación de la Matriz de Evolución (Ec. 29) en espacio k:*

12: $\phi_k^{\text{new}} \leftarrow C_k \cdot \phi_k + \frac{1}{\omega_k} S_k \cdot \dot{\phi}_k$

13: $\dot{\phi}_k^{\text{new}} \leftarrow -\omega_k S_k \cdot \phi_k + C_k \cdot \dot{\phi}_k$

14: *Actualizar estado y tiempo:*

15: $\phi_k \leftarrow \phi_k^{\text{new}}$

16: $\dot{\phi}_k \leftarrow \dot{\phi}_k^{\text{new}}$

17: $t \leftarrow t + dt$

18: **end while**

Paso 4: Recuperación al Espacio Real

19: $\phi(x, T_{max}) \leftarrow \text{Re}(\text{IFFT}(\phi_k))$

20: **return** Solución histórica $\phi(x, t)$

4.3. Resultados del método numérico

La posición inicial fue una gaussiana con $k_0 = 0.5$ y una desviación estandar de $\sigma = 1.0$, y una velocidad inicial nula.




Figura 1: Condición inicial, función gaussiana.

Bajo la evolución temporal de $t \rightarrow T_{max}$, se obtiene los siguientes comportamientos:




Figura 2: En la figura (a) se muestra la evolución del campo durante 36 seg de simulación acá se puede observar como el campo se dispersa en un cono de luz a la misma velocidad tanto a la izquierda como a la derecha. En la figura (b) se muestra la dispersión final en 2D del campo un a vez suelto en el campo infinito.

El video de la evolución temporal en $t = 0$ hasta $t = T_{max}$ se puede encontrar en el github ubicado en herramientas y repositorios, en la sección de resultados/análisis numérico.

5. Red Neuronal Informada por la física

Si bien las redes neuronales presentan una gran capacidad de aproximación a funciones, las arquitecturas profundas y altamente conectadas presentan dificultad para modelar soluciones de altas frecuencias y características multiescala (Wang et al., 2022). Según Wang et al. (2021), esto se atribuye a las interacciones conflictivas en la función de pérdida; sin embargo las causas fundamentales de este comportamiento aún no se comprenden totalmente.

Yu et al. (2022) propone el método de gPINN (gradient-enhanced PINN), el cual introduce un nuevo término en la función de pérdida basado en las derivadas del residual de la EDP; su argumento se basa en que si la EDP debe ser igual a cero en la solución, entonces su gradiente espacial también debe ser cero, anexando así restricciones que mejoran la precisión y la eficiencia del entrenamiento.

Wang et al. (2021) argumenta que el problema de usar un algoritmo como ADAM está en la rigidez en la dinámica del flujo de gradiente, esto quiere decir, las magnitudes de los gradientes que proviene del contorno ($\nabla_{\theta} \mathcal{L}_{bc}$) suele ser más grandes que los gradientes que provienen de la física ($\nabla_{\theta} \mathcal{L}_{phys}$);

debido a que ADAM intenta minimizar el error global, dedicará mucho tiempo en minimizar el error en el contorno ignorando los mínimos de la función de costo asociada a la física. Debido a esta rigidez, ADAM no puede atacar este problema con un solo parámetro (η). Esto modifica la función de pérdida para que ADAM intente minimizarla, en otras palabras, Wang et al. mejora el algoritmo. En este trabajo se presentará el optimizador ADAM y la modificación de Wang a la función de pérdida.

5.1. Definición de Red Neuronal Informada por la Física - PINN

La PINN es un método de machine learning que usa redes neuronales (perceptrones multicapas) para aproximar la solución de una EDP a través del conocimiento específico del dominio, la física y las condiciones iniciales. Partimos de la definición de la EDP:

Definición 5.1: EDP

Según Luo et al. (2025), una EDP es una función f que se define como:

$$\begin{aligned} f\left(\mathbf{x}, t, \frac{\partial \phi}{\partial x}, \frac{\partial \phi}{\partial t}, \boldsymbol{\lambda}\right) &= 0, \mathbf{x} \in \Omega, T \in [0, T], \\ \phi(\mathbf{x}, 0) &= h(\mathbf{x}), \mathbf{x} \in \Omega, \\ \phi(\mathbf{x}, t) &= g(\mathbf{x}, t), \mathbf{x} \in \partial\Omega, t \in [0, T], \end{aligned}$$

En donde, $\mathbf{x}$ son las variables espaciales, t representa el tiempo, $\frac{\partial}{\partial x}$ las dinámicas espaciales y $\frac{\partial}{\partial t}$ la evolución temporal. $\boldsymbol{\lambda} = [\lambda_1, \lambda_2, \dots, \lambda_n]$, representan los parámetros de la EDP. Ω y $\partial\Omega$ representan el dominio solución y su contorno. Las condiciones iniciales están dadas por $h(\mathbf{x})$ y las condiciones de contorno $g(\mathbf{x}, t)$.

Una PINN es un aproximador $\phi(\mathbf{x}, t; \boldsymbol{\theta}) = NN(\mathbf{x}, t)$ a la función $\phi(\mathbf{x}, t)$ solución de la EDP. De este modo, definimos el residuo como:

$$f\left(\mathbf{x}, t, \frac{\partial \phi}{\partial x}, \frac{\partial \phi}{\partial t}, \boldsymbol{\lambda}, \boldsymbol{\theta}\right) = \underbrace{r(\mathbf{x}, t, \boldsymbol{\theta})}_{\text{Residuo de la física}}. \quad (43)$$

5.2. Función Costo

Una buena aproximación es aquella que el residuo $r(\mathbf{x}, t, \boldsymbol{\theta})$ sea lo más cercano a cero. Se implementa una función de costo para la optimización de los parámetros capaces de minimizar el residuo físico.

$$\mathcal{L}(\boldsymbol{\theta}) = \mathcal{L}_{data}(\boldsymbol{\theta}) + \mathcal{L}_f(\boldsymbol{\theta}), \quad (44)$$

$$= \mathcal{L}_{bc}(\boldsymbol{\theta}, \mathcal{T}_{bc}) + \mathcal{L}_{bi}(\boldsymbol{\theta}, \mathcal{T}_{bi}) + \mathcal{L}_f(\boldsymbol{\theta}, \mathcal{T}_f). \quad (45)$$

En donde,

$$\mathcal{L}_f(\boldsymbol{\theta}, \mathcal{T}_f) = \frac{1}{|\mathcal{T}_f|} \sum_{\mathbf{x} \in \mathcal{T}_f} |r(\mathbf{x}, t, \boldsymbol{\theta})|^2, \quad (46)$$

$$\mathcal{L}_{ic}(\boldsymbol{\theta}, \mathcal{T}_{ic}) = \frac{1}{|\mathcal{T}_{ic}|} \sum_{\mathbf{x} \in \mathcal{T}_{ic}} |\phi(\mathbf{x}, 0, \boldsymbol{\theta}) - h(\mathbf{x}, 0)|^2, \quad (47)$$

$$\mathcal{L}_{bc}(\boldsymbol{\theta}, \mathcal{T}_{bc}) = \frac{1}{|\mathcal{T}_{bc}|} \sum_{\mathbf{x} \in \mathcal{T}_{bc}} |\phi(\mathbf{x}, t, \boldsymbol{\theta}) - g(\mathbf{x}, t)|^2. \quad (48)$$

Cuando se tiene datos experimentales, se debe agregar a la función de costo asociada a los datos.

5.3. Problema de optimización

5.3.1. Minimización con restricción de igualdad (restricción dura)

El problema de optimización recae en minimizar la función de pérdida de los datos $\mathcal{L}_{datos} = \mathcal{L}_{ic} + \mathcal{L}_{bc}$ con respecto a los parámetros $\boldsymbol{\theta}$ sujeto a la función de pérdida física $\mathcal{L}_f$ (Krishnapriyan et al., 2021):

$$\begin{aligned} \min_{\boldsymbol{\theta}} \quad & \mathcal{L}_{ic}(\boldsymbol{\theta}) + \mathcal{L}_{bc}(\boldsymbol{\theta}), \\ \text{s.a.} \quad & \mathcal{L}_f(\boldsymbol{\theta}) = 0. \end{aligned} \quad (49)$$

Según Krishnapriyan et al. (2021), esta aproximación es costosa de resolver. Esto se analiza con las condiciones de KKT de la optimización bajo las restricciones de igualdad.

5.3.1.1. Lagrangiano y condiciones KKT

Contruimos la función Lagrangiana introduciendo el vector dual $\boldsymbol{\lambda} \in \mathbb{R}^N$, dónde $N = 1$ para la ecuación 49, con esto obtenemos la ecuación 51:

$$\mathcal{L}(\boldsymbol{\theta}, \mathbf{v}) = \mathcal{L}(\boldsymbol{\theta})_{data} + \mathbf{v}^T h(\boldsymbol{\theta}), \quad (50)$$

$$= (\mathcal{L}_{ic}(\boldsymbol{\theta}) + \mathcal{L}_{bc}(\boldsymbol{\theta})) + v\mathcal{L}_f(\boldsymbol{\theta}). \quad (51)$$

Las condiciones KKT, una vez calculado el Lagrangiano, son:

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{ic}(\boldsymbol{\theta}^*) + \nabla_{\boldsymbol{\theta}} \mathcal{L}_{bc}(\boldsymbol{\theta}^*) + v \nabla_{\boldsymbol{\theta}} \mathcal{L}_f(\boldsymbol{\theta}^*) = 0, \quad (52)$$

$$\mathcal{L}_f(\boldsymbol{\theta}^*) = 0. \quad (53)$$

Analizando cada término de las ecuaciones,

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{ic}(\boldsymbol{\theta}^*) = \nabla_{\boldsymbol{\theta}} \left(\frac{1}{|\mathcal{T}_{ic}|} \sum_{x_{ic} \in \mathcal{T}_{ic}} |\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)|^2 \right), \quad (54)$$

$$= \frac{1}{|\mathcal{T}_{ic}|} \sum_{x \in \mathcal{T}_{ic}} \nabla_{\boldsymbol{\theta}} |\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)|^2, \quad (55)$$

$$= \frac{1}{|\mathcal{T}_{ic}|} \sum_{x \in \mathcal{T}_{ic}} 2[\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)] \nabla_{\boldsymbol{\theta}} (\phi(x, 0, \boldsymbol{\theta})), \quad (56)$$

$$= \frac{1}{|\mathcal{T}_{ic}|} \sum_{x \in \mathcal{T}_{ic}} 2(\nabla_{\boldsymbol{\theta}} \phi(x, 0, \boldsymbol{\theta})) \phi(x, 0, \boldsymbol{\theta}) - 2(\nabla_{\boldsymbol{\theta}} \phi(x, 0, \boldsymbol{\theta})) \phi(x, 0, \boldsymbol{\theta}) h(x, 0), \quad (57)$$

se encontró que el término $2(\nabla_{\boldsymbol{\theta}} \phi_{\theta}) \phi_{\theta}$ no es lineal porque ϕ_{θ} no es lineal y mucho menos su derivada; debido a esto, el término $2(\nabla_{\boldsymbol{\theta}} \phi_{\theta}) h$ tampoco es lineal. A su vez, el gradiente de la función de pérdida asociado a los valores iniciales no es lineal. Al desarrollar la derivada de la función de pérdida de los datos asociado al contorno, se encontraron terminos parecido, en dónde $2(\nabla_{\boldsymbol{\theta}} \phi_{\theta}) \phi_{\theta}$ y $2(\nabla_{\boldsymbol{\theta}} \phi_{\theta}) g$ estaban presentes, debido a la presencia de $\nabla_{\boldsymbol{\theta}} \phi_{\theta}$ la función de pérdida $\nabla_{\boldsymbol{\theta}} \mathcal{L}_{bc}$ tampoco es lineal.

La función de pérdida de interés $\mathcal{L}_f(\boldsymbol{\theta})$, trae consigo la dificultad de calcular su gradiente $\nabla_{\boldsymbol{\theta}} \mathcal{L}_f(\boldsymbol{\theta}^*)$ debido al compleja espacio y su no linealidad explícita e implícita; esto se puede observar en la ecuación (58) y (59),

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_f(\boldsymbol{\theta}^*) = \frac{1}{|\mathcal{T}_f|} \sum_{x \in \mathcal{T}_f} \nabla_{\boldsymbol{\theta}} \|(\partial_{tt} - \nabla^2 + m^2) \phi(x, t, \boldsymbol{\theta})\|^2, \quad (58)$$

$$= \frac{1}{|\mathcal{T}_f|} \sum_{x \in \mathcal{T}_f} 2 \left((\partial_{tt} - \nabla^2 + m^2) \phi(x, t, \boldsymbol{\theta}) \right) \left((\partial_{tt} - \nabla^2 + m^2) \nabla_{\boldsymbol{\theta}} \phi(x, t, \boldsymbol{\theta}) \right). \quad (59)$$

Para analizar la convexidad de las funciones de pérdida, se deberá calcular el Hessiano de cada función de pérdida $\nabla_{\boldsymbol{\theta}}^2 \mathcal{L}_i(\boldsymbol{\theta})$ y calcular los valores singulares, sin embargo, no se conoce la función aproximadora por NN, así que su cálculo es una tarea complicada. Según Boyd And Vandenberghe (2004), una función es convexa si su segunda derivada es definida postiva.

$$\nabla_{\boldsymbol{\theta}}^2 \mathcal{L}(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}}^2 \mathcal{L}_{ic}(\boldsymbol{\theta}) + \nabla_{\boldsymbol{\theta}}^2 \mathcal{L}_{bc}(\boldsymbol{\theta}) + \nabla_{\boldsymbol{\theta}}^2 \mathcal{L}_f(\boldsymbol{\theta}) \quad (60)$$

Una manera trivial de cumplir la condición de convexidad es que cada término involucrado en la función de pérdida total sea positivo; así el análisis se reduce a observar la positividad de los términos del Hessiano de la función total. Basta con analizar el Hessiano de alguno de las funciones de pérdida involucrada en los datos, para este caso, se analizó el término de las condiciones iniciales

$$\nabla_{\boldsymbol{\theta}}^2 \mathcal{L}_{ic}(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \left(\frac{1}{|\mathcal{T}_{ic}|} \sum_{x \in \mathcal{T}_{ic}} 2[\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)] \nabla_{\boldsymbol{\theta}} (\phi(x, 0, \boldsymbol{\theta})) \right), \quad (61)$$

$$= \frac{2}{|\mathcal{T}_{ic}|} \sum_{x \in \mathcal{T}_{ic}} \nabla_{\boldsymbol{\theta}} \left([\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)] \nabla_{\boldsymbol{\theta}} (\phi(x, 0, \boldsymbol{\theta})) \right), \quad (62)$$

$$= \frac{2}{|\mathcal{T}_{ic}|} \sum_{x \in \mathcal{T}_{ic}} [\nabla_{\boldsymbol{\theta}} \phi(x, 0, \boldsymbol{\theta})]^2 + [\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)] \nabla_{\boldsymbol{\theta}}^2 \phi(x, 0, \boldsymbol{\theta}). \quad (63)$$

El término $[\nabla_{\boldsymbol{\theta}} \phi(x, 0, \boldsymbol{\theta})]^2$ siempre es positivo. El análisis interesante está en el término $[\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)] \nabla_{\boldsymbol{\theta}}^2 \phi(x, 0, \boldsymbol{\theta})$ del cuál desconocemos si $[\phi(x, 0, \boldsymbol{\theta}) - h(x, 0)] \geq 0$, por lo que no se puede afirmar que este sea positivo. Sin embargo, sabemos que si la función de pérdida está cerca al optimo

θ^* , entonces este factor será lo suficientemente pequeño. El factor $\nabla_{\theta}^2 \phi(x, 0, \theta)$ es complicado de calcular, así que bastará con observar que si la función $\phi(x, 0, \theta)$ no es convexa tampoco lo será su Hessiana.

Definición 5.2: Función del perceptron

Para un solo layer de perceptrones (ejemplo más simple), la función aproximadora será:

$$\phi(\mathbf{y}, \theta) = \mathbf{b} + \mathbf{V}Z(\mathbf{c} + \mathbf{w} \cdot \mathbf{y}), \quad (64)$$

para cualquier valor de $\mathbf{y}$. En dónde $\theta = (\mathbf{b}, \mathbf{V}, \mathbf{c}, \mathbf{w})$ es el vector de parámetros y $\mathbf{y} = (\mathbf{x}, t)$ es el vector de entrada de datos.

De acuerdo de la definición 5.2 y la ecuación (64), se puede comprobar que la función $\phi(x, t, \theta)$ para cualquier valor de t no es convexa ni concava; para ello, debido a la definición de composición de funciones (Thomas & Weir, 2005):

Definición 5.3: Composición de funciones

Dadas f y g dos funciones, composición $f \circ g$ (f composición g) está definida por:

$$(f \circ g)(x) = f(g(x)) \quad (65)$$

El dominio de $f \circ g$ consiste en los números x del dominio de g para los que $g(x)$ está definido en el dominio de f .

Sea $\mathcal{L}_i(\theta) = f(g'(\theta))$, en dónde $g'(\theta) = \phi(x, 0, \theta) - h(x, 0)$, y $f(\cdot) = \|\cdot\|_2^2$; para que la composición $\mathcal{L}_i(\theta)$ sea convexa con respecto a θ debe cumplir estrictamente alguna de estas condiciones (Boyd & andenberghe, 2004) :

- la función externa es convexa y no decreciente en cada componente, y la función interna es convexa.
- La función externa es convexa y no creciente en cada componente, y la función interna es concava.

Debido a la que la función externa es convexa cumple el requisito de alguna de las dos, sin embargo, debido a la definición 5.2, la función aunque es afín en su estructura depende de $Z(\cdot)$ para que sea convexa o concava, sin embargo, usualmente esas funciones de activación no son ni convexas ni concavas, por lo que la función $\mathcal{L}_i(\theta)$ no es convexa.

Ahora, como no es convexo Boyd (2004) sugiere que si no se tiene certeza de comenzar el método iterativo de optimización en un el dominio factible, entonces se puede usar el método de Newton-No factible. Para encontrar el optimo y la variable dual analizamos aplicando Newton no factible debido a que $\mathcal{L}_{data}$ y $\mathcal{L}_f$ no son convexas y por lo tanto se desconoce la región de optimal. Se aplica el paso de newton $\nabla^2 f \delta_{nw} = -\nabla f$ a ambas variables (θ, λ) . Esto nos permite el siguiente sistema (Convex Optimization – Boyd And Vandenberghe, 2004):

$$\begin{pmatrix} \nabla_{\theta}^2 \mathcal{L}_{ic}(\theta^*) + \nabla_{\theta}^2 \mathcal{L}_{bc}(\theta^*) & (\nabla_{\theta} \mathcal{L}(\theta)_f)^T \\ \nabla_{\theta} \mathcal{L}(\theta)_f & 0 \end{pmatrix} \begin{pmatrix} \delta_{\theta}^N \\ \delta_v^N \end{pmatrix} = - \begin{pmatrix} \nabla_{\theta} \mathcal{L}_{ic}(\theta) + \nabla_{\theta} \mathcal{L}_{bc}(\theta^*) \\ \mathcal{L}(\theta) \end{pmatrix}. \quad (66)$$

Aplicar este método consume recursos computacionales significativos debido a que debe calcular el Hessiano de la función aproximadora ϕ_{θ} dos veces para la función de pérdida asociada a las datos de condiciones iniciales y de frontera, y a su vez, el Hessiano de la función física asociado a las coordenadas espaciales de mi gradiente de función de pérdida física es costoso.

5.3.1.2. Análisis de costo computacional

Para analizar el costo computacional, partimos por el teorema de "aproximación universal" discutido por LeCun et al. (2015) que establece que una red lo suficientemente grande es buena aproximadora y logra cualquier grado de precisión que deseemos, pero no dice cuán grande será esta red; y a su vez, Delalleau y Bengio (2011) demostraron que una red profunda puede representar ciertas familias de polinomios de manera eficiente, mientras que una red superficial requeriría un número de perceptrones exponencialmente mayor para representar la misma función. Con esto, reconoceremos que PINN debe ser profunda como larga. La arquitectura que Wang et al. (2021) usó, fue de 50 neuronas y de 4 a 6 capas ocultas. Con este cálculo podemos analizar el costo computacional de implemetar Newton no factible para solucionar con rapidez la optimización:

- El costo computacional de calcular la Hessiana está dado por el número de parámetros que tiene la PINN, para un perceptron estandard, los pesos (conectar un layer de 50 neuronas con otro layer de 50 neuronas) obtenemos que son $50 \times 50 = 2500$, con 50 sesgos incluidos en la nueva layer, esto nos da un total por capa de 2550 parámetros.
- Como son 6 capas y cada capa tiene 50 neuronas, obtenemos un total de $6 \times 2550 = 15300$ parámetros en total.

La complejidad del cálculo del Hessiano en el peor de los casos está dada por $H(n^2)$, tendra una complejidad computacional cercana a 234.090.000 elementos, en precisión simple, esto es cercano a la giga-Bytes de información. El cálculo de ∇_{θ} depende de mi función física, lo cuál es un poco más complicada:

$$\nabla_{\theta} \mathcal{L}_f(\theta) = \nabla_{\theta} \left(\frac{1}{|N_f|} \sum_{x_f \in N_f} \|\partial_{tt}\phi(x, t; \theta) - \nabla^2 \phi(x, t; \theta) + m^2 \phi(x, t; \theta)\|_2^2 \right) \quad (67)$$

$$= \frac{2}{|N_f|} \sum_{x_f \in N_f} \left(\partial_{tt}(\nabla_{\theta} \phi(x, t; \theta)) - \nabla^2(\nabla_{\theta} \phi(x, t; \theta)) + m^2(\nabla_{\theta} \phi(x, t; \theta)) \right). \quad (68)$$

Notese que el término $\nabla_{\theta}(\mathcal{L}_f)$ requiere calcular la derivada de los parámetros θ a través de las derivadas temporales y espaciales de la red (∂_{tt}, ∇^2), lo que incrementa la complijidad computacional en comparación con una red Neuronal estandard.

Como resultado, realizar el método de Newton infactible es altamente costoso. Wang et al. (2021) también presenta otro inconveniente en el cálculo del Hessiano físico, este introduce el problema de la rigidez, analizan los autovalores de la matriz Hessiana de la función de pérdida física y observan que hay bastante dispersión entre los autovalores (muy mal condicionada), lo cuál el método de Newton requeriría de muchas iteraciones para cumplir con la función de costos física. Más sin embargo, también en la escalabilidad Newton es intratable.

5.3.2. Minimización sin restricciones - regularización

Krishnapriyan et al. (2021), propone tratar la restricción de igualdad dura como una restricción blanda, es decir, usar una constante de regularización en la función objetivo, esto convierte el problema de optimización con restricción en un problema de optimización sin restricción Multi-Objetivo (MO). Boyd & Vandenberghe (2004), en su libro de optimización convexa, definen el problema de optimización vectorial como:

$$\begin{aligned} \text{mín} \quad & f_0(x) \\ \text{s.a} \quad & f_i(x) \leq 0, \\ & h_j(x) = 0. \end{aligned} \quad (69)$$

En donde $f_0(x)$ y $f_i(x)$ son convexas y $h_j(x)$ es afín. También, $x \in \mathbb{R}^n$ es la variable de optimización, $K \subseteq \mathbb{R}^q$ es un cono propio, $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ es la función objetivo, $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son las restricciones de desigualdad, y $h_i : \mathbb{R}^p \rightarrow \mathbb{R}$ son las restricciones de igualdad. También define el conjunto de todos los valores alcanzables $\mathcal{O}$ como:

$$\mathcal{O} = \{f_0(x) \mid \exists x \in \mathcal{D}, f_i(x) \leq 0, i = 1, 2, \dots, m; h_j(x) = 0, j = 1, \dots, p\}. \quad (70)$$

Si x^* es un punto optimo, entonces $f_0(x)$, el objetivo puede compararse con cualquier otro punto factible, y debe ser mejor o igual a él. Entonces, un punto x^* es óptimo si y solo si es factible y

$$\mathcal{O} \subseteq f_0(x^*) + K. \quad (71)$$

En donde el conjunto $f_0(x^*) + K$ es el cono propio definido centrado en $f_0(x^*)$ que define la relación de orden, es decir, quien es mayor a la función optima; el cono se define como: $K = \mathbb{R}_+^q$. Ahora, el cono me dice la región en donde están los peores resultados. Si K me apunta hacia donde están los peores resultados, entonces $-K$ me apunta hacia donde están los mejores resultados, es decir, que si estoy en $f_0(x)$ y miro en la dirección $-K$ y veo que no hay ningún otro valor $f(y) \subseteq \mathcal{O}$, entonces quiere decir que estoy en un valor de Pareto. Un valor de Pareto es un punto factible x^* y es un minimal del conjunto de valores alcanzables $\mathcal{O}$, los puntos de Pareto son aquellos que pertenecen al conjunto de Pareto definido:

$$\mathcal{P} \subseteq \mathcal{O} \cap \text{bd}\mathcal{O}. \quad (72)$$

Es decir, pertenece al borde del conjunto de valores objetivo alcanzables. De este mismo modo, introducimos el problema de minimización de Krishnapriyan et al. (2021):

$$\min_{(\boldsymbol{\theta}, \lambda)} \left(\mathcal{L}_{ic}(\boldsymbol{\theta}) + \mathcal{L}_{bc}(\boldsymbol{\theta}) \right) + \lambda_f \mathcal{L}_f(\boldsymbol{\theta}) \quad (73)$$

Si $\lambda_f = 1$, esto es lo que se conoce como “Vanilla PINN”. En donde, $\lambda \geq_{K^*} 0$ representa todos los vectores del hiperplano que sostienen al conjunto $\mathcal{O}$ en el óptimo encontrado como punto de contacto. Esto presupone un problema debido si el conjunto $\mathcal{O}$ no es convexo entonces hay posibles valores de Pareto en las regiones inalcanzables del conjunto, por lo que, la regularización no podrá encontrar todos los puntos de Pareto pero si algunos que también minimizan la función objetivo. La formulación del problema de optimización se puede generalizar aún más de la siguiente manera (Rohrhofer et al., 2023):

$$\min_{(\boldsymbol{\theta}, \lambda)} \sum_{i \in \{f, ic, bc\}} \lambda_i \mathcal{L}_i(\boldsymbol{\theta}) \quad (74)$$

En esta formulación, si $\lambda_f = 1$, entonces es igual a la función de pérdida propuesta por Wang et al. (2021) que regulariza las funciones de pérdida de los datos, y la función de pérdida de la física. Esto, visto de otra manera, es una reformulación a la función de pérdida de la PINN. Para tratar esto, propone la siguiente representación:

$$\min_{(\boldsymbol{\theta}, \lambda)} \mathcal{L}_f(\boldsymbol{\theta}) + \sum_{i \in \{ic, bc\}} \lambda_i \mathcal{L}_i(\boldsymbol{\theta}) \quad (75)$$

Así logra el equilibrio entre los gradientes de las funciones de pérdida de los datos y la física, respectivamente; el método de este artículo asegura que este equilibrio se logra ajustando los parámetros involucrados impidiendo que un término gobierne al otro. Para resolver esto, Wang et al. (2021) usa ADAM bajo el método de *Learning Rate Annelaing (LRA)* para evitar el problema tratado anteriormente y que Rohrhofer et al. (2023) introdujo como el problema del “frente de Pareto aparente”, que establece que usando métodos de gradiente (Newton, ADAM, SGD, etc.) alcanzan un conjunto de valores óptimos locales en las funciones de pérdida, obteniendo el mismo problema de los gradientes que obtuvo Wang et al. (2021).

5.3.2.1. Condiciones KKT

Analizamos las condiciones KKT, en este caso, la única condición es la condición de primer orden para óptimos locales:

$$\nabla_{\boldsymbol{\theta}} \left(\lambda_{ic} \mathcal{L}_{ic}(\boldsymbol{\theta}) + \lambda_{bc} \mathcal{L}_{bc}(\boldsymbol{\theta}) \right) + \nabla_{\boldsymbol{\theta}} \mathcal{L}_f(\boldsymbol{\theta}) = 0 \quad (76)$$

$$\underbrace{\nabla_{\boldsymbol{\theta}} \left(\lambda_{ic} \mathcal{L}_{ic}(\boldsymbol{\theta}) + \lambda_{bc} \mathcal{L}_{bc}(\boldsymbol{\theta}) \right)}_{\text{Gradiente de los datos}} = \underbrace{-\nabla_{\boldsymbol{\theta}} \mathcal{L}_f(\boldsymbol{\theta})}_{\text{Gradiente de la física}} \quad (77)$$

Obteniendo así, dos gradientes de diferentes funciones de pérdida que deben ser iguales en magnitud pero de dirección contraria. Aquí, si $\lambda_{ic} = \lambda_{bc} = 1$, se tiene el problema de desequilibrio de gradientes debido a que los gradientes de la función de pérdida física suele ser mayores y tener comportamientos más rígidos que los gradientes de los datos. Los λ de la regularización, se pueden calcular de la siguiente forma:

$$\lambda_i = \frac{\max_{\boldsymbol{\theta}} |\nabla_{\boldsymbol{\theta}} \mathcal{L}_f(\boldsymbol{\theta}_n)|}{|\nabla_{\boldsymbol{\theta}} \mathcal{L}_i(\boldsymbol{\theta}_n)|} \quad (78)$$

Dónde el numerador tiene el gradiente máximo de la función física y denominador tiene el promedio. Al usar el máximo en la función de pérdida se captura la rigidez máxima de la ecuación diferencial actuando como un límite superior que representa el peor de los escenarios y después promediado funcionando como un regularizador. En la mayoría de situaciones λ_i deberá ser mayor a uno, más sin embargo un análisis general de las posibles situaciones me indicarían lo siguiente:

- Si $\lambda_i = 1$, entonces en promedio el gradiente del dato i es igual al peor de los casos del gradiente físico, esto me daría el mismo problema que teníamos antes, como consecuencia la optimización no podrá salir de la región de valores de Pareto aparente (situación ideal).
- Si $\lambda_i < 1$, entonces en promedio el gradiente del dato i es mayor al peor caso del gradiente de la optimización, como consecuencia le daría más peso al este gradiente de la función de dato i , y así el optimizador exploraría otra región de Pareto con minimales inexplorados.
- Si $\lambda_i > 1$, entonces el máximo del gradiente de la física es mayor al promedio del gradiente del dato i , como consecuencia estaría en una región de Pareto más reducida.

5.3.2.2. Análisis de rigidez (Stiffness)

Como vimos antes, los gradientes de la función física son mayores y más rígidos. Esto se mencionó sin analizar a profundidad. Para su análisis, Wang et. al. (2021), usó la función de pérdida de la *Vanilla PINN* y el método *steepest gradient* como optimizador:

$$\theta_{n+1} = \theta(n) - \eta \nabla_{\theta} \mathcal{L}(\theta_n) \quad (79)$$

$$= \theta(n) - \eta [\nabla_{\theta} \mathcal{L}_f(\theta_n) + \nabla_{\theta} \mathcal{L}_{data}(\theta_n)] \quad (80)$$

En dónde η es la tasa de aprendizaje o el paso. Aplican expansión de la serie de Taylor hasta el término de segundo orden,

$$\mathcal{L}(\theta_{n+1}) = \mathcal{L}(\theta_n) + (\theta_{n+1} - \theta_n)^T \cdot \nabla_{\theta} \mathcal{L}(\theta_n) + \frac{1}{2} (\theta_{n+1} - \theta_n)^T \nabla_{\theta}^2 \mathcal{L}(\xi) (\theta_{n+1} - \theta_n) \quad (19) \quad (81)$$

Si usamos la siguiente relación $\theta_{n+1} - \theta_n = -\eta \nabla_{\theta} \mathcal{L}(\theta)$ y reemplazamos en la expansión de Taylor, encontramos la diferencia que hay entre el paso $n + 1$ y n está dada por:

$$\mathcal{L}(\theta_{n+1}) - \mathcal{L}(\theta_n) = -\eta \nabla_{\theta_n} \mathcal{L}(\theta)^T \cdot \nabla_{\theta_n} \mathcal{L}(\theta_n) + \frac{1}{2} \eta^2 \nabla_{\theta} \mathcal{L}(\theta_n)^T \nabla_{\theta}^2 \mathcal{L}(\xi) \nabla_{\theta} \mathcal{L}(\theta_n) \quad (82)$$

$$= -\eta \|\nabla_{\theta_n} \mathcal{L}(\theta)\|_2^2 + \frac{1}{2} \eta^2 \nabla_{\theta} \mathcal{L}(\theta_n)^T \nabla_{\theta}^2 \mathcal{L}(\xi) \nabla_{\theta} \mathcal{L}(\theta_n) \quad (83)$$

$$= -\eta \|\nabla_{\theta_n} \mathcal{L}(\theta)\|_2^2 + \frac{1}{2} \eta^2 \nabla_{\theta} \mathcal{L}(\theta_n)^T (\nabla_{\theta}^2 \mathcal{L}_f(\xi) + \nabla_{\theta}^2 \mathcal{L}_{data}(\xi)) \nabla_{\theta} \mathcal{L}(\theta_n) \quad (84)$$

$$= -\eta \|\nabla_{\theta_n} \mathcal{L}(\theta)\|_2^2 + \frac{1}{2} \eta^2 \nabla_{\theta} \mathcal{L}(\theta_n)^T \nabla_{\theta}^2 \mathcal{L}_f(\xi) \nabla_{\theta} \mathcal{L}(\theta_n) + \frac{1}{2} \eta^2 \nabla_{\theta} \mathcal{L}(\theta_n)^T \nabla_{\theta}^2 \mathcal{L}_{data}(\xi) \nabla_{\theta} \mathcal{L}(\theta_n) \quad (85)$$

. Vale analizar cada término acá, el término $\eta \|\nabla_{\theta_n} \mathcal{L}(\theta)\|_2^2$ me representa el valor del gradiente al cuadrado por la tasa de aprendizaje, normalmente es pequeña; y vemos un término de interés:

$$\nabla_{\theta} \mathcal{L}(\theta_n)^T \nabla_{\theta}^2 \mathcal{L}(\xi) \nabla_{\theta} \mathcal{L}(\theta_n) = \frac{\|\nabla_{\theta} \mathcal{L}(\theta_n)\|_2^2}{\|\nabla_{\theta} \mathcal{L}(\theta_n)\|_2^2} \left(\nabla_{\theta} \mathcal{L}(\theta_n)^T \nabla_{\theta}^2 \mathcal{L}(\xi) \nabla_{\theta} \mathcal{L}(\theta_n) \right) \quad (86)$$

$$= \|\nabla_{\theta} \mathcal{L}(\theta_n)\|_2^2 \left(\frac{\nabla_{\theta} \mathcal{L}(\theta_n)^T}{\|\nabla_{\theta} \mathcal{L}(\theta_n)\|} \nabla_{\theta}^2 \mathcal{L}(\xi) \frac{\nabla_{\theta} \mathcal{L}(\theta_n)}{\|\nabla_{\theta} \mathcal{L}(\theta_n)\|} \right). \quad (87)$$

Por el teorema de descomposición de autovalores (Trefethen & Bau, 1997), una matriz cuadrada y de columnas independientes entre sí, puede descomponerse en una matriz Q ortogonal que contiene sus autovectores y una matriz $diag(\lambda_1, \lambda_2, \dots, \lambda_N)$, de este modo $\nabla_{\theta} \mathcal{L}(\theta) = Q^T \mathbf{diag}(\lambda_1, \lambda_2, \dots, \lambda_N) Q$, de este modo la expresión anterior se puede analizar:

$$\nabla_{\theta} \mathcal{L}(\theta_n)^T \nabla_{\theta}^2 \mathcal{L}(\xi) \nabla_{\theta} \mathcal{L}(\theta_n) = \|\nabla_{\theta} \mathcal{L}(\theta_n)\|_2^2 (x^T Q^T \mathbf{diag}(\lambda_1, \lambda_2, \dots, \lambda_N) Q x) \quad (88)$$

$$= \|\nabla_{\theta} \mathcal{L}(\theta_n)\|_2^2 (y^T \mathbf{diag}(\lambda_1, \lambda_2, \dots, \lambda_N) y) \quad (89)$$

$$= \|\nabla_{\theta} \mathcal{L}(\theta_n)\|_2^2 \sum_{i=1}^N \lambda_i y_i^2. \quad (90)$$

En dónde, $y = xQ$, $x = \frac{\nabla_{\theta} \mathcal{L}(\theta_n)}{\|\nabla_{\theta} \mathcal{L}(\theta_n)\|}$, Q es una matriz ortogonal que diagonaliza $\nabla_{\theta}^2 \mathcal{L}(\xi)$, y $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_N$ son los autovalores de $\nabla_{\theta}^2 \mathcal{L}(\xi)$. Con este mismo procedimiento y la descomposición de $\nabla_{\theta}^2 \mathcal{L}(\xi)$ en las funciones de pérdida física y de los datos se encuentran los autovalores respectivos. Partiendo del resultado de la ecuación (90) y agregándolo a la ecuación (83), obtenemos:

$$\mathcal{L}(\theta_{n+1}) - \mathcal{L}(\theta_n) = -\eta \|\nabla_{\theta} \mathcal{L}(\theta)\|_2^2 + \frac{1}{2} \eta \|\nabla_{\theta} \mathcal{L}(\theta)\|_2^2 \sum_{i=1}^N \lambda_i y_i^2 \quad (91)$$

$$= \eta \|\nabla_{\theta} \mathcal{L}\|_2^2 \left(-1 + \frac{1}{2} \eta \sum_{i=1}^N \lambda_i y_i^2 \right). \quad (92)$$

Para que el método de optimización funcione, se quiere que $\mathcal{L}_f(\theta_{n+1}) < \mathcal{L}_f(\theta_n)$, por lo tanto el lado izquierdo de la ecuación (91) debe ser negativo, para esto los términos dentro del paréntesis debe ser negativos y cumplir $1 > \frac{1}{2} \eta \sum_{i=1}^N \lambda_i y_i^2$. Esto solo es posible si los valores propios son pequeños (la función de pérdida cercana al mínimo es suave y bien comportada), sin embargo, si es complicada, tenemos que los valores propios son grandes y en vez de seguir el camino de descenso se aleja saltando a otro valle. En detalle, se descompone la función de pérdida en múltiples funciones

objetivos:

$$\mathcal{L}_f(\boldsymbol{\theta}_{n+1}) - \mathcal{L}_f(\boldsymbol{\theta}_n) = \eta \|\nabla \mathcal{L}_f(\boldsymbol{\theta})\|^2 \left(-1 + \frac{1}{2} \eta \sum_{i=1}^N \lambda_i^f y_i^2 \right), \quad (93)$$

$$\mathcal{L}_{ic}(\boldsymbol{\theta}_{n+1}) - \mathcal{L}_{ic}(\boldsymbol{\theta}_n) = \eta \|\nabla \mathcal{L}_{ic}(\boldsymbol{\theta})\|^2 \left(-1 + \frac{1}{2} \eta \sum_{i=1}^N \lambda_i^{ic} y_i^2 \right), \quad (94)$$

$$\mathcal{L}_{bc}(\boldsymbol{\theta}_{n+1}) - \mathcal{L}_{bc}(\boldsymbol{\theta}_n) = \eta \|\nabla \mathcal{L}_{bc}(\boldsymbol{\theta})\|^2 \left(-1 + \frac{1}{2} \eta \sum_{i=1}^N \lambda_i^{bc} y_i^2 \right). \quad (95)$$

Acá, de acuerdo a Wang et al. (2021) la causante del desequilibrio del gradiente está en los autovalores λ_i^f asociados a la función de pérdida física, siendo estos muy grandes cercano a un minimal.

5.3.2.3. Análisis de cotas

Wang et al. (2021), desarrolla el análisis de cotas a partir de las desigualdades de Sobolev a $\nabla_{\theta} \mathcal{L}_f$ y $\nabla_{\theta} \mathcal{L}_{data}$:

$$\|\nabla_{\theta} \mathcal{L}_f(\theta)\|_{L^{\infty}} \leq C \|\nabla_{\theta}^2 \mathcal{L}_f(\theta)\|_{L^{\infty}}, \quad (96)$$

$$\|\nabla_{\theta} \mathcal{L}_{data}(\theta)\|_{L^{\infty}} \leq C \|\nabla_{\theta}^2 \mathcal{L}_{data}(\theta)\|_{L^{\infty}}. \quad (97)$$

Esto nos impone que el máximo valor del gradiente está acotado por el máximo valor de su curvatura de la función de pérdida, conectado con los valores propios del Hessiano de la función de pérdida, usaremos la relación (2.3.11) del libro Numerical linear algebra de Trefethen & Bau (1997), sea el Hessiano $H \in \mathbb{R}^{N \times N}$ donde N es el número de *puntos de colocación* y $(1/\sqrt{N})\|H\|_{\infty} \leq \|H\|_2 \leq \sqrt{N}\|H\|_{\infty}$, entonces las desigualdades de Sobolev tendrían relación directa con los autovalores del Hessiano de las funciones de pérdida físicas y de los datos;

$$\|\nabla_{\theta} \mathcal{L}_f(\theta)\|_{L^{\infty}} \leq C\sqrt{N} \|\nabla_{\theta}^2 \mathcal{L}_f(\theta)\|_{L^2} = C\sqrt{N} \sqrt{\max \lambda_f(H_f^T H_f)}, \quad (98)$$

$$\|\nabla_{\theta} \mathcal{L}_{data}(\theta)\|_{L^{\infty}} \leq C\sqrt{N} \|\nabla_{\theta}^2 \mathcal{L}_{data}(\theta)\|_{L^2} = C\sqrt{N} \sqrt{\max \lambda_{data}(H_{data}^T H_{data})}. \quad (99)$$

Así que el valor del gradiente está acotado por el máximo autovalor de su curvatura. Esto implica que un autovalor grande de $H^T H$ habilita la existencia de valores grandes del gradiente, mientras que un autovalor pequeño restringe el gradiente a valores pequeños. Por lo tanto, se puede reafirmar el desequilibrio entre gradientes.

5.4. Learning rate annealing for PINN

Partimos de la función objetivo de la ecuación 76, y minimizamos con respecto a un método de primer orden en el gradiente:

$$\boldsymbol{\theta}_{n+1} = \boldsymbol{\theta}_n - \eta \left[\nabla_{\theta} \mathcal{L}_f(\boldsymbol{\theta}) + \sum_{i \in \{ic, bc\}} \lambda_i \nabla_{\theta} \mathcal{L}_i(\boldsymbol{\theta}) \right] \quad (100)$$

Se calcula los pesos de las funciones de pérdida de las condiciones iniciales y de contorno usando la ecuación (78), y se actualiza usando una función de media móvil para eliminar el ruido generado por los gradientes en el entrenamiento:

$$\lambda_i = (1 - \alpha) \lambda_i + \alpha \hat{\lambda}_i. \quad (101)$$

Para posteriormente actualizar los pesos bajo la ecuación (100) con los nuevos lambdas. El algoritmo propuesto por Wang et al. (2021), está dado por el algoritmo 2 con la modificación de no usar SGD sino Adam como optimizador como una aproximación al Gradiente Natural de Fisher.

5.5. ADAM

Para entender el método Adam, se debe partir del *Gradiente Natural de Fisher* (Pascanu & Bengio, 2013;), esto quiere decir que el gradiente ya no se movera por el espacio euclideo común y corriente sino que se movera através del espacio de distribución de probabilidades bajo la métrica de Kullback-Leibur (KL) que tiene para cada camino. Para esto, se debe introducir la matriz de fisher en el método de gradiente descendente:

$$\boldsymbol{\theta}_{n+1} = \boldsymbol{\theta}_n - \eta \underbrace{F^{-1}}_{\text{Matriz de fisher}} \nabla_{\theta} \mathcal{L}(\boldsymbol{\theta}) \quad (102)$$

Algorithm 2 Algoritmo de LRA + ADAM**Require:** Hiperparámetros recomendados: $\eta = 10^{-3}$, $\alpha = 0.9$.**Require:** Número de pasos S , número de restricciones M .**Require:** Pesos iniciales λ_i para cada término de pérdida $i = 1, \dots, M$.**Bucle de Entrenamiento**

```

1: for  $n \leftarrow 1$  to  $S$  do
    (a) Cálculo de estadísticas de gradiente
2:     Calcular el máximo gradiente del residuo físico:
3:      $G_{max} \leftarrow \max_{\theta} \{|\nabla_{\theta} \mathcal{L}_r(\theta_n)|\}$ 
4:     Calcular la media del gradiente para cada término  $i$ :
5:      $G_{mean}^i \leftarrow |\nabla_{\theta} \mathcal{L}_i(\theta_n)|$ 
6:      $\hat{\lambda}_i \leftarrow \frac{G_{max}}{G_{mean}^i}$  ▷ (Ec. 78)
    (b) Actualización de pesos (Promedio Móvil)
7:     Actualizar  $\lambda_i$  usando el factor de suavizado  $\alpha$ :
8:      $\lambda_i \leftarrow (1 - \alpha)\lambda_i + \alpha\hat{\lambda}_i$  ▷ (Ec. 101)
    (c) Actualización de Parámetros de la Red
9:     Calcular gradiente total ponderado:
10:     $\nabla_{total} \leftarrow \nabla_{\theta} \mathcal{L}_r(\theta_n) + \sum_{i=1}^M \lambda_i \nabla_{\theta} \mathcal{L}_i(\theta_n)$ 
11:    Aplicar ADAM:
12:     $\theta_{n+1} \leftarrow \theta_n - \eta \nabla_{total}$  ▷ (Ec. 100)
13: end for
14: return Parámetros optimizados  $\theta_{S+1}$ 

```

La matriz de Fisher contiene las varianzas y covarianzas de los diferentes pasos estocásticos generados por los *minibatches* del método del descenso del gradiente. Los autores Pascany & Bengio (2013) definieron la matriz de Fisher:

$$F = \underbrace{\mathbb{E}[\nabla_{\theta} \text{Log}(P(x|\theta)) \cdot \nabla_{\theta} \text{Log}(P(x|\theta))^T]}_{\text{Segundo momento}} \quad (103)$$

De acuerdo con la ecuación (102), la matriz de Fisher es el segundo momento de $\nabla_{\theta} \text{Log}(P(x|\theta))$, lo que parece ser el gradiente de una típica función de pérdida para una función de probabilidad (Amari, 1998). El método de Adam, asume que los parámetros son independientes entre sí y por tal motivo solo sobreviven los elementos de la diagonal de Fisher, y así el método del descenso es una aproximación al método del Gradiente Natural de Fisher ():

$$\theta_{n+1} = \theta_n - \eta \underbrace{\text{diag}(F^{-1})}_{\text{Varianza}} \underbrace{\nabla_{\theta} \mathcal{L}(\theta)}_{\text{Primer momento}}. \quad (104)$$

Aparte de esto, Adam conserva el decaimiento exponencial del momento como lo hace el método de Momento de una manera similar (Ruder, 2016), y anexa el segundo momento como cercanía al método Natural de Fisher:

$$\theta_{n+1} = \theta_n - \eta \frac{m_t}{\sqrt{v_t}} \quad (105)$$

En dónde:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} \mathcal{L}(\theta), \quad (106)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} \mathcal{L}(\theta))^2. \quad (107)$$

Acá Adam (2014) aclaró que usó la raíz cuadrada del inverso de la matriz de varianza debido a que conservaría invarianza en la escala del gradiente y es un preconditionador más conservador, es decir, en el método de Gradiente Natural de Fisher, si la curvatura de Fisher es pequeña entonces asume que está en una maceta y da un paso muy grande para poder atravesarla, debido a que tenemos funciones no convexas esto puede ser omitir minimos locales, así que para mitigar este problema no usa la varianza total sino la raíz cuadrada de la varianza, algo así como un desviación estandard.

6. Implementación

6.1. Normalización de las variables

La normalización de las variables permite comparar a la misma escala las variables, asegurando una contribución uniforme en el entrenamiento de aprendizaje de la NN, por tal motivo conduce a

resultados de aprendizaje más precisos (Xu et al., 2025). El proceso de Normalización que se usó fue el método de "min-max" modificado para escalarlo al rango de $[-1, 1]$:

$$x_{norm} = 2 \frac{x - x_{min}}{x_{max} - x_{min}} - 1, \quad (108)$$

$$t_{norm} = 2 \frac{t - t_{min}}{t_{max} - t_{min}} - 1. \quad (109)$$

Al usar este proceso de escalador, podemos ver que hay una constante de escalamiento:

$$x_{norm} = \alpha_x(x - x_{min}) - 1, \quad (110)$$

$$t_{norm} = \alpha_t(t - t_{min}) - 1. \quad (111)$$

En dónde $\alpha_x = 2/(x_{max} - x_{min})$ Y $\alpha_t = 2/(t_{max} - t_{min})$. Ahora, como las funciones de pérdida expresan la física o el fenómeno en los dominios originales, entonces existe un escalamiento α_i que:

$$\frac{\partial}{\partial x} = \alpha_x \frac{\partial}{\partial x_{norm}}, \quad \frac{\partial^2}{\partial x^2} = \alpha_x^2 \frac{\partial^2}{\partial x_{norm}^2}, \quad (112)$$

$$\frac{\partial}{\partial t} = \alpha_t \frac{\partial}{\partial t_{norm}}, \quad \frac{\partial^2}{\partial t^2} = \alpha_t^2 \frac{\partial^2}{\partial t_{norm}^2}. \quad (113)$$

Y así obtener, la función de pérdida de la física se debe escalar de esta manera, al igual que la función de pérdida de la condición inicial y la condición de contorno para mantener el dominio de la física original en las escalas de $x, t = [-1, 1]$.

$$(\alpha_t^2 \partial_{tt} - \alpha_x^2 \nabla^2 + m^2) \phi(\mathbf{x}_{norm}, \mathbf{t}_{norm}; \boldsymbol{\theta}) = 0 \quad (114)$$

6.2. Función de activación - SIREN

Para el entrenamiento de la PINN de EDP periódicas o con solución aproximada de la serie de Fourier, Sitzmann et al. (2020) propone la metodología SIREN con funciones de activación sinusoidales:

$$\Phi(\mathbf{x}) = \mathbf{W}_n(\phi_{n-1} \circ \phi_{n-2} \circ \dots \phi_0)(\mathbf{x}) + \mathbf{b}_n, \quad \phi_i(\mathbf{x}_i) = \sin(\mathbf{W}_i \mathbf{x}_i + \mathbf{b}_i). \quad (115)$$

El autor argumentó que al usar SIREN debe realizarse ajustes en la metodología de iniciación de los parámetros, esto es debido a la linealidad que tiene el seno en valores cercanos a su cero, si los pesos se inician en valores muy pequeños, entonces la función de activación perdería su poder de representación para funciones continuas. Para esto, analizaron la distribución de señal de salida en cada capa. En la capa input se asume que la distribución es uniforme, al ser procesada por la función de activación sinusoidal la señal de salida cambia a una distribución arcoseno; al tener varias capas la distribución U (arcoseno) por el teorema del límite central se va volviendo una distribución normal. Los autores proponen que para tener estabilidad se debe controlar la varianza de la distribución U en las capas finales de las capas ocultas. Para la elección de los pesos, propusieron:

$$w_i \sim \mathcal{U}\left(-\sqrt{\frac{6}{n}}, \sqrt{\frac{6}{n}}\right), \quad (116)$$

donde n es el número de entradas de la neurona. Ahora para la atacar el problema de valores pequeños (bajas frecuencias), se propone un factor w_0 grande que escale los frecuencias y así pueda tener la representación de la función seno, transformando la función sinusoidal a

$$\sin(w_0 \mathbf{W}_i \mathbf{x}_i + \mathbf{b}_i). \quad (117)$$

Encontrando que un valor $w_0 = 30$ funciona bastante bien.

6.3. Parámetros iniciales y arquitectura

Se usó una arquitectura de 128 neuronas por capa oculta con un total de 6 capas ocultas debido al teorema de aproximación universal, una red profunda pero más ancha; esta arquitectura se obtuvo bajo experimentaciones hasta obtener un buen desempeño.

Se usó ADAM + LRA como primera instancia para la caracterización de mínimos dentro del conjunto de los valores alcanzables, se corrió con un total de 100.000 iteraciones con un decaimiento exponencial de la tasa de aprendizaje, los valores iniciales del decaimiento fueron: $\eta_0 = 1 \times 10^{-4}$, tasa de decaimiento de 0.95 cada 1.500 iteraciones, además cada 10 iteraciones se calculaba los pesos de la función de pérdida de las condiciones iniciales y de frontera y se actualizaban bajo una

media móvil con un $\alpha = 0.95$, se usó los pesos iniciales de $w_0 = [1.0, 1.0, 1.0]$; para terminar se usó un algoritmo de muestreo aleatorio para que generara nuevas (x_i, t_i) donde $i \in \{f, ic, bc\}$ para cada iteración (Wang et al., 2021; Liu et al., 2022). Así, se inició con puntos de colocación de 128 para cada dominio de cada función de pérdida, es decir, $x_i, t_I = 128$; de este modo, al finalizar las 50.000 iteraciones, la red neuronal se entrenó con un total de 6.4 millones de puntos de colocación sin asfixiar la memoria RAM.

Las condiciones físicas que se usaron fueron las mismas que se usaron en la simulación numérica. Después de usar ADAM + LRA para encontrar una región dónde se encuentra el valor óptimo, se usó una variante del método L-BFGS como minimizador final, se usaron criterio de parada de 5000 iteraciones o una tolerancia de epsilon de máquina $1.0 + \text{eps}1.0$, como parámetros de inicialización se guardó los pesos y los parámetros de la red para cargarlos y así tener algo de "memoria" de la primera etapa.

7. Resultados y Discusiones

El optimizador ADAM + LRA logró reducir la función de pérdida total a ordenes de 10^{-5} tras 100.000 épocas, con una tasa de aprendizaje de $\approx 3.27 \times 10^{-6}$ y con unos pesos de la función de pérdida finales de $[1.0, 4.90, 0.82]$, logrando la estabilidad en un valor de Pareto.




Figura 3: Gráfica de funciones de pérdida a través de las épocas de entrenamiento. Aunque se ve que hay una aparente convergencia, el método ADAM es lento al converger a mínimos pero es rápido acercándose cuando hay un equilibrio de gradientes, como no lo hay, para eso se usó LRA, se ve hay mucho ruido producto de el cambio de pesos cada 10 épocas. El método SIREN favorece a las condiciones de contorno, por tal motivo, puede alcanzar valores cercanos al orden de 10^{-12} . La función de pérdida total quedó en manos de la función de pérdida de la física (PDE) y condición inicial.

El optimizador de segundo orden L-BFGS refinó la solución, alcanzando una pérdida total de ordenes 10^{-8} ; este valor tan bajo indica que la red neuronal ha encontrado un valor de Pareto que satisface la EDP de Klein-Gordon y las condiciones iniciales y de contorno. En este proceso, la función de pérdida de la EDP logra una rápida convergencia, indicando un aprendizaje fuerte en la ecuación de Klein-Gordon, es decir, aprendió a no violar las leyes físicas. Las curvas pertenecientes a las condiciones tanto iniciales como de contorno, siguen siendo bajas indicando que es más fácil para la función adaptarse a los valores internos del dominio que a los valores fijos de la frontera; sin embargo, estos valores son relativamente buenos. El optimizador ha logrado una convergencia en menos de 500 épocas, lo que indica que los pesos heredados fueron buenos como para que el optimizador pudiera llegar a una convergencia casi pareja en todas las funciones de pérdida. En la gráfica 6, se muestra que si llegó a un punto de Pareto bastante bien.

Aunque la red Neuronal haya logrado aprender muy bien la condición inicial (pulso gaussiano) como se muestra en la figura 6, la validación con la simulación numérica muestra conflictos; el cálculo del error relativo L_2 muestra un error del 9.53 %, esto se puede interpretar como una buena representación de los datos numéricos y la PINN puesto que encontró un valor de Pareto aparente con una convergencia de orden baja 10^{-8} .




Figura 4: Gráfica de funciones de pérdida a través de las épocas de entrenamiento. A diferencia del entrenamiento de ADAM + LRA, se ve que es coherente con el método de L-BFGS porque presenta curvas suaves, no hay explosiones numéricas y hay convergencia.




Figura 5: Gráfica de diagnóstico de la condición inicial. Acá, podemos ver que se ajusta muy bien al comportamiento estático cuando $t = 0$, lo que podemos decir que la NN aprendió muy bien a interpretar la condición inicial para luego manipularla bajo la EDP aprendida.




Figura 6: Gráficas comparativas de representación de la PINN con respecto a su simulación en los planos x y t , acá se puede observar que la PINN logra generar el cono de la velocidad de grupo de las ondas más rápidas (dentro del cono de luz), más sin embargo, en temas de amplitud y es inconsistente todavía.

8. Recursos

Todos los recursos se encuentran en el siguiente github: https://github.com/Emmaquantum/Optimization_PINN.git

9. Anexos

9.1. Ecuación de Dirac y Ecuación de Klein-Gordon

Dado que cada componente del espinor de Dirac satisface individualmente la ecuación de Klein-Gordon (Bjorken & Drell, 1964), el estudio de la dinámica de paquetes de onda y dispersión relativista puede realizarse válidamente en el formalismo escalar de Klein-Gordon. Sea la ecuación de Dirac:

$$(i\gamma^\mu \partial_\mu - m)\psi = 0 \quad (118)$$

Aplicamos el operador conjugado:

$$(i\gamma^\nu \partial_\nu - m)(i\gamma^\mu \partial_\mu - m)\psi = 0 \quad (119)$$

$$\underbrace{(-i\gamma^\nu \partial_\nu)(i\gamma^\mu \partial_\mu)\psi}_{\text{Término cinético}} - \underbrace{(-i\gamma^\nu \partial_\nu)m\psi - m(i\gamma^\mu \partial_\mu)\psi}_{\text{se cancelan}} + \underbrace{(-m)(-m)\psi}_{\text{Término de masa}} = 0 \quad (120)$$

$$(\gamma^\nu \gamma^\mu \partial_\nu \partial_\mu + m^2)\psi = 0 \quad (121)$$

El producto de matrices $\{\gamma^\nu, \gamma^\mu\} = 2g^{\nu\mu}$ y a su vez $g^{\nu\mu}\partial_\nu = \partial^\mu$, así que nos queda:

$$(\partial^\mu \partial_\mu + m^2)\psi = 0 \quad (122)$$

$$(\partial^t \partial_t - \nabla^2 + m^2)\psi = 0 \quad (123)$$

A lo que llegamos a la ecuación de Klein-Gordon.

9.2. Matriz de Fisher

Sea la medida de Kullback-Leibler (KL) (Pascanu & Bengio, 2014):

$$KL(\theta||\theta + \delta) \approx \mathbb{E}[\text{Log}(P(x|\theta)) - \text{Log}(P(x|\theta + \delta))] \quad (124)$$

Realizando la expansión a $\text{Log}(P(x|\theta + \delta))$ obtenemos lo siguiente:

$$\text{Log}(P(x|\theta + \delta)) \approx \text{Log}P(x|\theta) + \left(\nabla \text{Log}P(x|\theta)\right)^T \delta + \frac{1}{2}\delta^T \nabla^2 \text{Log}P(x|\theta)\delta \quad (125)$$

Sustituimos en la ecuación (113) y obtenemos:

$$KL(\theta||\theta + \delta) \approx \mathbb{E}[\text{Log}P(x|\theta) - \text{Log}P(x|\theta) - \left(\nabla_\theta \text{Log}P(x|\theta)\right)^T \delta - \frac{1}{2}\delta^T \nabla_\theta^2 \text{Log}P(x|\theta)\delta] \quad (126)$$

El gradiente $\nabla_\theta \text{Log}P(x|\theta) \approx 0$ cuando se θ se acerca al optimal θ^* , haciendo esto en el optimal, obtenemos lo siguiente:

$$KL(\theta^*||\theta^* + \delta) \approx \mathbb{E}\left[-\frac{1}{2}\delta^T \nabla_\theta^2 \text{Log}P(x|\theta^*)\delta\right] \quad (127)$$

$$= -\frac{1}{2}\delta^T \underbrace{\mathbb{E}[\nabla_\theta^2 \text{Log}P(x|\theta^*)]}_{\text{Matriz F}} \delta \quad (128)$$

Debido a las siguiente propiedades:

$$\int P(x|\theta)dx = 1 \quad (129)$$

$$\int \nabla_\theta P(x|\theta)dx = \nabla_\theta(1) = 0 \quad (130)$$

$$\nabla_\theta \text{Log}P(x|\theta) = \frac{1}{P(x|\theta)} \nabla_\theta P(x|\theta) \quad (131)$$

$$\int P(x|\theta) \nabla_\theta \text{Log}P(x|\theta)dx = 0 \quad (132)$$

La segunda derivada ∇_θ^2 está dada por:

$$\int P(x|\theta) \nabla_\theta \text{Log}P(x|\theta)dx = 0 \quad (133)$$

$$\nabla_\theta \int P(x|\theta) \nabla_\theta \text{Log}P(x|\theta)dx = 0 \quad (134)$$

$$\int \nabla_\theta P(x|\theta) \nabla_\theta \text{Log}P(x|\theta) + P(x|\theta) (\nabla_\theta^2 \text{Log}P(x|\theta))dx = 0 \quad (135)$$

$$\int P(x|\theta) \left(\nabla_\theta \text{Log}P(x|\theta) \nabla_\theta \text{Log}P(x|\theta) \right) + P(x|\theta) (\nabla_\theta^2 \text{Log}P(x|\theta))dx = 0 \quad (136)$$

Factorizando $P(x|\theta)$ en la ecuación (125), obtenemos que:

$$\int P(x|\theta) \left[\left(\nabla_{\theta} \text{Log} P(x|\theta) \right)^2 + \left(\nabla_{\theta}^2 \text{Log} P(x|\theta) \right) \right] dx = 0 \quad (137)$$

Encontramos que la ecuación (126) es la esperanza del segundo momento:

$$\mathbb{E} \left[\left(\nabla_{\theta} \text{Log} P(x|\theta) \right)^2 + \left(\nabla_{\theta}^2 \text{Log} P(x|\theta) \right) \right] = 0 \quad (138)$$

$$\mathbb{E} \left[\left(\nabla_{\theta} \text{Log} P(x|\theta) \right)^2 \right] + \mathbb{E} \left[\left(\nabla_{\theta}^2 \text{Log} P(x|\theta) \right) \right] = 0 \quad (139)$$

$$(140)$$

Y así encontramos la relación:

$$\mathbb{E} \left[\left(\nabla_{\theta} \text{Log} P(x|\theta) \right)^2 \right] = -\mathbb{E} \left[\left(\nabla_{\theta}^2 \text{Log} P(x|\theta) \right) \right] \quad (141)$$

Y por lo tanto,

$$KL(\theta||\theta + \delta) \approx \frac{1}{2} \delta^T \mathbb{E} \left[\left(\nabla_{\theta} \text{Log} P(x|\theta) \right)^2 \right] \delta, \quad (142)$$

$$= \frac{1}{2} \delta^T \mathbb{E} \left[\left(\nabla_{\theta} \text{Log} P(x|\theta) \right) \left(\nabla_{\theta} \text{Log} P(x|\theta) \right)^T \right] \delta, \quad (143)$$

$$= \frac{1}{2} \delta^T F \delta. \quad (144)$$

10. Referencias

Referencias

- [1] Adam, K. D. B. J. (2014). A method for stochastic optimization. arXiv preprint arXiv:1412.6980, 1412(6).
- [2] Amari, S. I. (1998). Natural gradient works efficiently in learning. *Neural computation*, 10(2), 251-276.
- [3] Boyd, S., & Vandenberghe, L. (2004). *Convex optimization*. Cambridge university press.
- [4] Bjorken, J. D., & Drell, S. D. (1964). *Relativistic quantum mechanics*. (No Title).
- [5] Castro, G. V. (2018). SOLUCIÓN DE LA ECUACIÓN DE KLEIN-GORDON Y SU GENERALIZACIÓN FRACCIONARIA (Doctoral dissertation, Universidad de La Habana).
- [6] Delalleau, O., & Bengio, Y. (2011). Shallow vs. deep sum-product networks. *Advances in neural information processing systems*, 24.
- [7] Hochbruck, M., & Ostermann, A. (2010). Exponential integrators. *Acta Numerica*, 19, 209-286.
- [8] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *nature*, 521(7553), 436-444.
- [9] Liu, Y., Cai, L., Chen, Y., & Wang, B. (2022). Physics-informed neural networks based on adaptive weighted loss functions for Hamilton-Jacobi equations. *Math. Biosci. Eng.*, 19(12), 12866-12896.
- [10] Krishnapriyan, A., Gholami, A., Zhe, S., Kirby, R., & Mahoney, M. W. (2021). Characterizing possible failure modes in physics-informed neural networks. *Advances in neural information processing systems*, 34, 26548-26560.
- [11] Luo, K., Zhao, J., Wang, Y., Li, J., Wen, J., Liang, J., ... & Liao, S. (2025). Physics-informed neural networks for PDE problems: A comprehensive review. *Artificial Intelligence Review*, 58(10), 323.
- [12] Ruder, S. (2016). An overview of gradient descent optimization algorithms. arXiv preprint arXiv:1609.04747.
- [13] Pascanu, R., & Bengio, Y. (2013). Revisiting natural gradient for deep networks. arXiv preprint arXiv:1301.3584.
- [14] Peng, W., Zhou, W., Zhang, J., & Yao, W. (2020). Accelerating physics-informed neural network training with prior dictionaries. arXiv preprint arXiv:2004.08151.
- [15] Sitzmann, V., Martel, J., Bergman, A., Lindell, D., & Wetzstein, G. (2020). Implicit neural representations with periodic activation functions. *Advances in neural information processing systems*, 33, 7462-7473.
- [16] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational physics*, 378, 686-707.
- [17] Rohrhofer, F. M., Posch, S., Gößnitzer, C., & Geiger, B. C. (2023). Data vs. physics: The apparent Pareto front of physics-informed neural networks. *IEEE Access*, 11, 86252-86261.
- [18] Thomas, G. B., & Weir, M. D. (2005). *Cálculo: una variable*. Pearson Educación.
- [19] Trefethen, L. N., & Bau, D. (1997). *Numerical linear algebra*. Society for Industrial and Applied Mathematics
- [20] Wang, S., Teng, Y., & Perdikaris, P. (2021). Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5), A3055-A3081.
- [21] Wang, S., Yu, X., & Perdikaris, P. (2022). When and why PINNs fail to train: A neural tangent kernel perspective. *Journal of Computational Physics*, 449, 110768.
- [22] Xu, S., Dai, Y., Yan, C., Sun, Z., Huang, R., Guo, D., & Yang, G. (2025). On the preprocessing of physics-informed neural networks: How to better utilize data in fluid mechanics. *Journal of Computational Physics*, 528, 113837.

-
- [23] Yu, J., Lu, L., Meng, X., & Karniadakis, G. E. (2022). Gradient-enhanced physics-informed neural networks for forward and inverse PDE problems. *Computer Methods in Applied Mechanics and Engineering*, 393, 114823.